Jazyk Python

Údajové štruktúry, numpy a pandas
prednáška 4

Ústav umelej inteligencie
Technická univerzita v Košiciach
Ing. Ján Magyar, PhD.

Údajová štruktúra

- všeobecný popis
- implementovaná cez údajové typy
- zvyčajne sa skladá zo skupiny elementárnych hodnôt
- cieľom je zvýšiť efektivitu práce s údajmi
- štandardizované šablóny pre reprezentáciu údajov v počítačoch
- rôzne úrovne abstrakcie
- vieme ich implementovať rôznymi spôsobmi, ale spôsob fungovania sa nemení

Vybrané údajové štruktúry

- polia
- zoznamy
- zásobníky
- fronty
- hašovacie tabuľky
- stromy

Pole (Array)

- (viacrozmerné) usporiadanie hodnôt rovnakého typu
- k údajom pristupujeme pomocou indexov – na základe ukladania v pamäti
- v Pythone dve možnosti:
  - zoznam zoznamov (zoznamov zoznamov...)
  - pomocou knižnice `numpy`
    - C-čková implementácia polí
    - vyšší výkon a rýchlejšie výpočty ako pomocou zoznamov

Numpy

- implementácia polí v Pythone (v skutočnosti sú to matice)
- podobné, ako zoznamy, iba nemeniteľné (hodnoty však vieme aktualizovať)
- vytvorenie polí:

```
import numpy as np
my_array = np.array([2, 3, 4])
```

- konvertovanie vstupu na pole:

```
numpy.asarray(a, dtype=None, order=None)
```

Typ polí

- každé pole má typ `ndarray`, jednotlivé prvky musia byť rovnakého typu `my_array.dtype`

- typy prvkov nie sú Pythonovské primitívne typy, sú to vlastné implementácie knižnice `numpy`

Tvar polí

- celkový počet prvkov: `my_array.size`
- každé pole má jednu alebo viac dimenzií
- tvar poľa je definovaný rozmermi
  `my_array.shape`

- vracia n-ticu s rozmermi, napr.: `(2, 3)`, kde prvá hodnota je vonkajší rozmer, a postupujeme smerom dnu
- ak je pole dvojdimenzionálne, prvý rozmer je počet riadkov, druhý je počet stĺpcov*

Úprava rozmerov poľa

- `numpy.reshape(array, newshape, order='C')`
  - upraví tvar poľa na požadované rozmery
  - počet prvkov v poli a počet prvkov v novom tvare musí byť rovnaký
  - order určí poradie pridávania prvkov (`C` alebo `F`)
  - vracia nové pole
  - -1 na automatické výpočty rozmeru

- `numpy.flatten(order='C')`
  - vracia nové pole – vektorová reprezentácia (jeden riadok, resp. stĺpec)

zeros(), ones() a full()

- metódy slúžia na inicializáciu matice s hodnotami 0, 1 alebo vlastnou hodnotou

- `numpy.zeros(shape, dtype=float, order='C')`
- `numpy.ones(shape, dtype=float, order='C')`
- `numpy.full(shape, fill_value, dtype=None, order='C')`
- `numpy.empty(shape, dtype=float, order='C, *, like=None)`

Generovanie rozsahov

- `numpy.arange(start, stop, step)`
  - funguje rovnako ako `range()`
  - možnosť práce s floatmi – skôr použiť `linspace`
- `numpy.linspace(start, stop, num=50, endpoint=True)`
  - vygeneruje `num` hodnôt v rovnakej vzdialenosti od seba v intervale `[start, stop]`
  - `endpoint` určí, či interval má obsahovať hodnotu `stop`

Pridávanie prvkov

- implementuje konkatenáciu polí

- `numpy.hstack(tup)`
  `numpy.hstack((array1, array2))`
- `numpy.vstack(tup)`
  `numpy.vstack((array1, array2))`

- pre dynamické vytvorenie polí je lepšie použiť zoznamy, a následne vygenerovať pole

Indexovanie a slicing v numpy

- zásady sú rovnaké ako v Pythone, numpy ale umožňuje skrátený zápis

```
np.array([(1,2,3), (4,5,6)])
print('First row:', e[0])
print('Second column:', e[:,1])
print('Second row, first two values:', e[1, :2])
```

Indexovanie pomocou polí

- ako index vieme použiť aj druhé pole – načítajú sa hodnoty pod indexom podľa druhého poľa
- druhé pole môže mať rôzne tvary – určí tvar výsledku
- vieme použiť aj viac polí, kde hodnoty udávajú index po jednotlivé dimenzie

Podmienené indexovanie

- výsledky podmienok vieme použiť aj na podmienené indexovanie, teda na generovanie masiek

```
a = np.arange(12).reshape(3, 4)
b = a > 4
a[b]
a[b] = 0
```

vyberie hodnoty väčšie ako 4

vynulujeme dané čísla

Aritmetické operácie nad maticami

- primitívne operácie fungujú element-wise

```
test = np.array([1, 2, 3])
test += 1

test [2, 3, 4]
```

- ak je potrebné pretypovanie, tak sa to robí na všeobecnejší typ

Štatistické metódy

- `np.min(array) / np.argmin(array)`
- `np.max(array) / np.argmax(array)`
- `np.mean(array)`
- `np.median(array)`
- `np.std(array)`

- všetky podporujú parameter `axis`, ktorý určí, po ktorej osi sa má vypočítať štatistická metrika
- numpy ponúka aj matematické funkcie (napr. `sin`, `cos`, `exp`, `sqrt`)

Maticové operácie

- `np.transpose(array, axes=None)`
- `np.dot(array1, array2)`
- `np.matmul(array1, array2)`
  - ak polia sú dvojrozmerné – štandardné násobenie
  - ak polia majú jeden rozmer – vygeneruje sa z nich dvojrozmerné pole
  - ak polia majú viac rozmerov, ako dva – považujú sa za zásobník dvojrozmerných matíc
- násobenie matíc je možné aj cez operátor `@` alebo `array1.dot(array2)`

Kópie a viewy

- pomocou metódy `view()` vieme vytvoriť pohľad na pôvodné pole

```
c = a.view()
c is a              False
c.base is a         True
```

- používajte metódy `copy()` pre hlboké kópie

```
d = a.copy()
```

Pandas

- knižnica pre dátovú analytiku
- nadstavba nad `numpy`
- pre tabuľkové údaje a časové rady
- umožňuje všeobecné indexovanie (cez názvy stĺpcov)
- zvyčajne sa používa s importom
  `import pandas as pd`

Základné objekty

- postupnosť prvkov – `Series`

```
s = pd.Series([1, 3, 5, np.nan, 6, 8])
```

- údajový rámec – `DataFrame`

```
my_ids = pd.date_range("20220214", periods=4)

df = pd.DataFrame(
    np.random.randn(4, 4),
    index=my_ids,
    columns=['A', 'B', 'C', ,D'])
```

Generovanie údajových rámcov

- z dictionary
```
df2 = pd.DataFrame({
    "A": 1.0,
    "B": "2022-02-14",
    "C": ["test", "train", "eval", "train"]
})
```

- načítanie zo súboru, napr.
```
df3 = pd.read_csv(path, sep=',')
```

Indexovanie v dataframeoch

- funguje všeobecné Pythonovské indexovanie
- ďalšie pomocné možnosti prístupu: `at`, `iat`, `loc`, `iloc`
- výber stĺpca (vráti postupnosť `Series`)
  `df["A"]`
- výber riadkov
  `df[0:3]`
  podľa indexov
  `df["20220214":"20220216"]`
- výber riadkov a stĺpcov
  `df.loc["20220214":"20220216", ["A", "B"]]`
- `iat` a `iloc` fungujú podobne ale iba s číselnými indexmi

Podmienený výber

- pomocou podmienok (podmieňovacie operátory)
  `df[df["A"] > 0]`

- pre filtrovanie môžeme použiť metódu `isin()`
  `df[df["C"].isin(["test", "train"])]`

Nastavenie hodnôt

- rozšírenie o stĺpec:
  `df["F"] = "new"`

- nastavenie hodnoty podľa (číselného) indexu
  `df.at[0, "A"] = 0 / df.iat[0, "A"] = 0`

- nastavenie niekoľkých hodnôt pomocou polí
  `df.loc[:, "D"] = np.array([5] * len(df))`

- podmienené nastavenie (napr. nastavenie na absolútne hodnoty)
  `df[df < 0] = -df`

Základná práca s dataframeami

- ukážkové riadky zo začiatku/konca dataframeu
  `df.head(n=g) / df.tail(n=5)`
- získanie zoznamu indexov a stĺpcov
  `df.index / df.columns`
- konvertovanie na `numpy` polia (iba pri rovnakých údajových typoch)
  `df.to_numpy()`
- prehľad štatistických metrík
  `df.describe()`
- transpozícia
  `df.T`

Triedenie údajov v dataframeoch

- triedenie indexov
  `df.sort_index(axis=1, ascending=False)`

- triedenie podľa hodnôt
  `df.sort_values(by="B")`

Spracovanie chýbajúcich hodnôt

- vymazanie riadkov s chýbajúcimi hodnotami
  `df.dropna(how="any")`

- doplnenie chýbajúcich hodnôt
  `df.fillna(value=0)`

- získanie prehľadu o prítomnosti chýbajúcich hodnôt
  `pd.isna(df)`

Štatistické metódy

- priemer podľa stĺpcov / riadkov
  `df.mean() / df.mean(1)`

- aplikácia ľubovoľnej funkcie
  ```
  df.apply(np.cumsum)  # suma
  df.apply(lambda x: x.max() - x.min())
  ```

- početnosť hodnôt
  `df["C"].value_counts()`

Ďalšia funkcionalita

- konkatenácia – `concat()`
- spojenie ako v SQL – `join()`
- zgrupovanie – `groupby()`
  `df.groupby("A") / df.groupby(["A", "B"])`
- zhustenie / rozbalenie dimenzií
  `df.stack() / df.unstack()`

Spojkový zoznam

- lineárna skupina údajov, kde prvky nemusia byť uložené v pamäti vedľa seba
- každý prvok obsahuje
  - údaj
  - odkaz na ďalší prvok v zozname (alebo `NULL`)
- efektívne pridávanie nových prvkov na ľubovoľnú pozíciu
- varianty
  - obojsmerné spojkové zoznamy
  - kruhové spojkové zoznamy

Jednosmerný spojkový zoznam

Obojsmerný spojkový zoznam

Kruhový zoznam

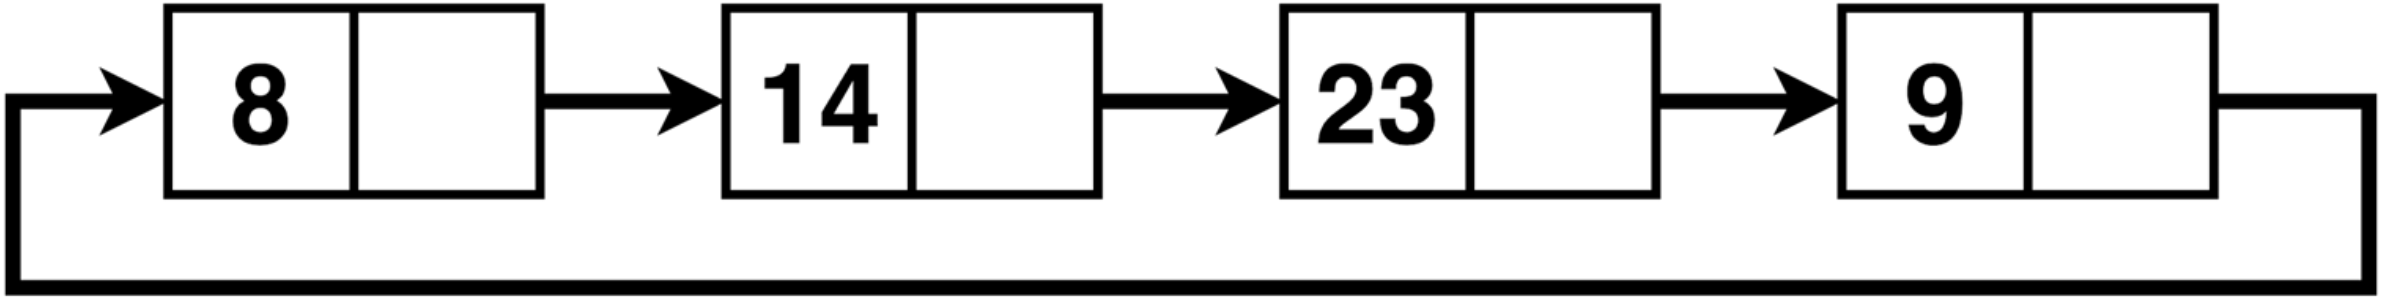

Porovnanie polí a spojkových zoznamov

Operácia	**Pole**	**Spojkový zoznam**
Pristupovanie	*O(1)*	*O(n)*
Pridanie na začiatok	*O(n)*	*O(1)*
Pridanie (priemer)	*O(n)*	*O(1)**
Pridanie na koniec	*O(1)*	*O(n)*
Zmazanie	*O(1)/O(n)*	*O(1)**

Zoznamy (list) v Pythone

- zoznamy môžu obsahovať hodnoty rôznych typov – ako zabezpečiť konštantný čas pristupovania k jednotlivým prvkom?
- na najvyššej vrstve sú zoznamy implementované ako spojkové zoznamy

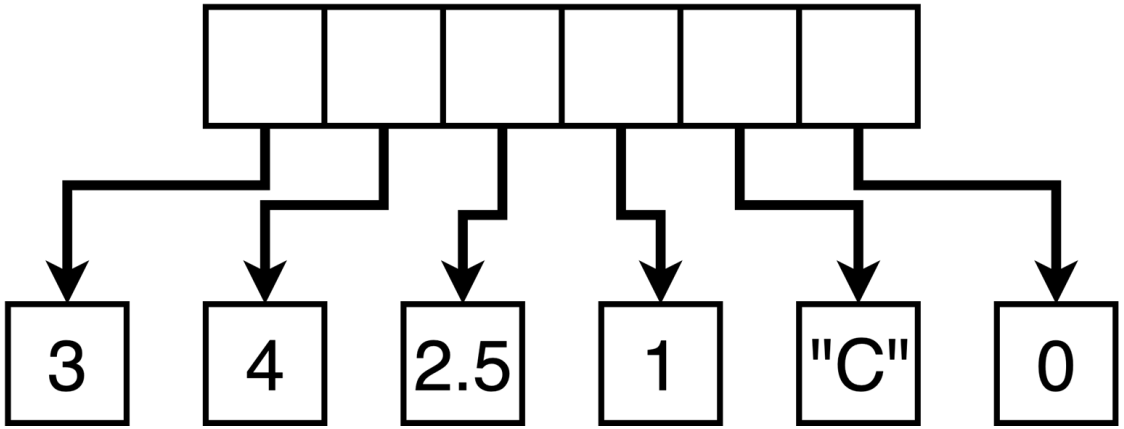

Zásobník (Stack)

- dynamická množina prvkov typu LIFO – last-in, first-out
- základné operácie:
  - inicializácia – CREATE
    - vytvorí prázdny zásobník, môže byť súčasťou PUSH
  - pridanie – PUSH
    - pridá prvok na vrchol zásobníku
  - zmazanie – POP
    - zmaže prvok z vrcholu zásobníku
  - prístup ku vrcholnému prvku – TOP
  - prázdnosť zásobníku – IS_EMPTY

Použitie zásobníkov

- backtracking pri algoritmoch kde hľadáme riešenie princípom pokus-omyl
  - vyhľadávanie do hĺbky
- zásobník volaní

Front (Queue)

- dynamická množina prvkov typu FIFO – first-in, first-out
- základné operácie:
  - inicializácia – CREATE
    - vytvorí prázdny front, môže byť súčasťou ENQUEUE
  - pridanie – ENQUEUE
    - pridá prvok na koniec frontu
  - zmazanie – DEQUEUE
    - vymaže prvok zo začiatku
  - prístup k prvému prvku – HEAD
  - prístup k ostatným prvkom – TAIL
  - prázdnosť frontu – IS_EMPTY

Použitie frontov

- spracovanie požiadaviek
- komunikácia medzi dvomi procesmi
- posielanie správ
- dočasné ukladanie údajov pre neskoršie spracovanie

LIFO/FIFO

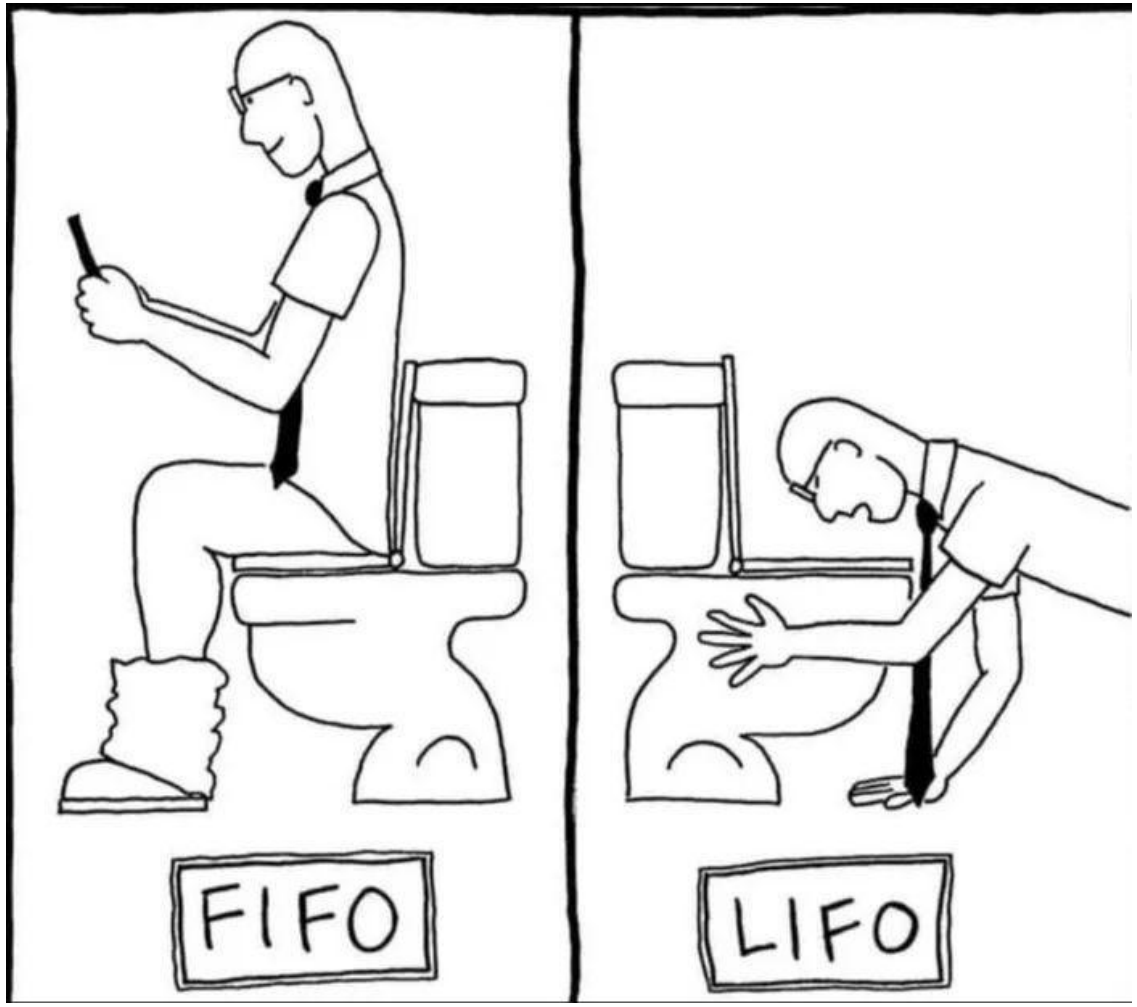

Hašovanie

- rozdeľuje údaje na menšie skupiny (buckety)
- predpokladá sa, že pristupovanie k jednotlivým skupinám sa uskutoční v konštantnom čase
- zjednodušuje vyhľadávanie z $O(n)$ na $O(n/k)$ v ideálnom prípade, kde k je počet skupín (bucketov)
- spracovanie hodnoty sa uskutoční v niekoľkých krokoch
  1. hašovacia funkcia vypočíta hash hodnotu
  2. pristupujeme ku skupine na základe hash hodnoty (použije sa ako kľúč)
  3. vykoná sa požadovaná operácia (pridávanie, načítanie, zmazanie)

Hašovacia funkcia

- vstupom je hodnota určitého typu, ktorú funkcia mapuje na hash hodnotu
- hash hodnota je vždy jednoduchšia ako vstup
- funkcia dáva vždy rovnaký výstup pre ten istý vstup
- ten istý výstup môže byť vypočítaný pre rôzne vstupy (kolízia)
- obor hodnôt (výstupy) je zvyčajne presne definovaný interval (množina hodnôt)
- ideálna hašovacia funkcia mapuje vstupné hodnoty do skupín uniformne, t.j. každá skupina bude mať približne rovnaký počet prvkov

Hašovacia tabuľka

- údajová štruktúra typu asociatívne pole
- obsahuje hodnoty typu kľúč-hodnota
- kľúč môže byť
  - výsledok hašovacej funkcie

```
idx = hash_function(input_value)
```

  - výsledok hašovacej funkcie namapovaný na určité čísla:

```
hash_value = hash_function(input_value)
idx = hash_value % number_of_buckets
```

Riešenie kolízií

- ideálna hašovacia funkcia by mala prideliť práve jeden prvok do každej skupiny
- v skutočnosti sa dochádza ku kolíziám, každá hodnota v hash tabuľke je v podstate zoznam (môže byť implementovaný rôznymi spôsobmi)
- efektivita hashovania sa vyhodnocuje na základe load factoru:

$$load\ factor = n/k$$

n - počet hodnôt
k - počet bucketov

Hashovanie - ukážka

- hašovacia funkcia - zvyšok po delení 5

1	13	24	3	6	12	54	63

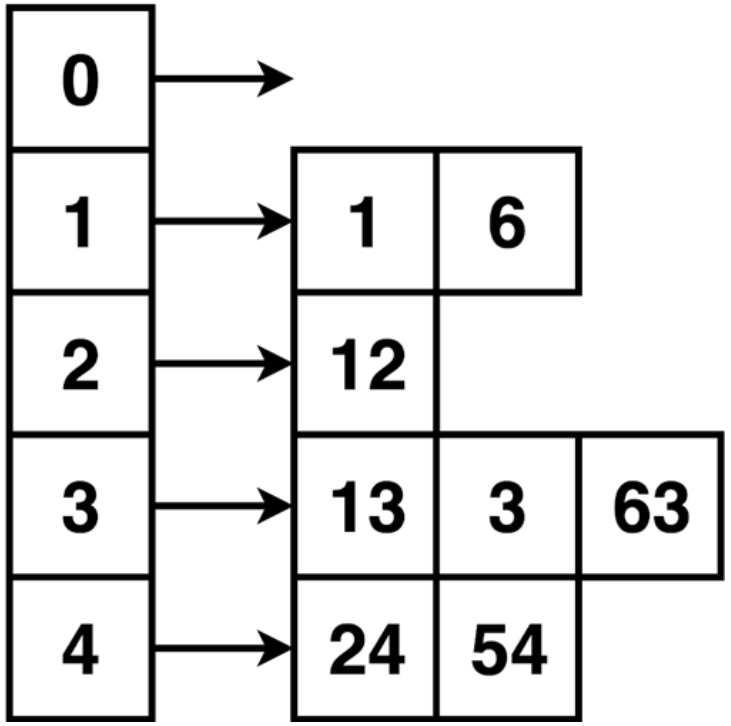

Stromy

- všeobecná údajová štruktúra, ktorá usporiada prvky do hierarchie
- strom sa skladá z uzlov (node), ktoré môžu mať potomkov (children)
- každý uzol obsahuje hodnotu a odkaz na potomkov
- uzol bez predkov (parents) je koreňový uzol (root node)
- uzol bez potomkov je listový uzol alebo list (leaf node)
- každý potomok je ďalší strom – rekurzívna definícia

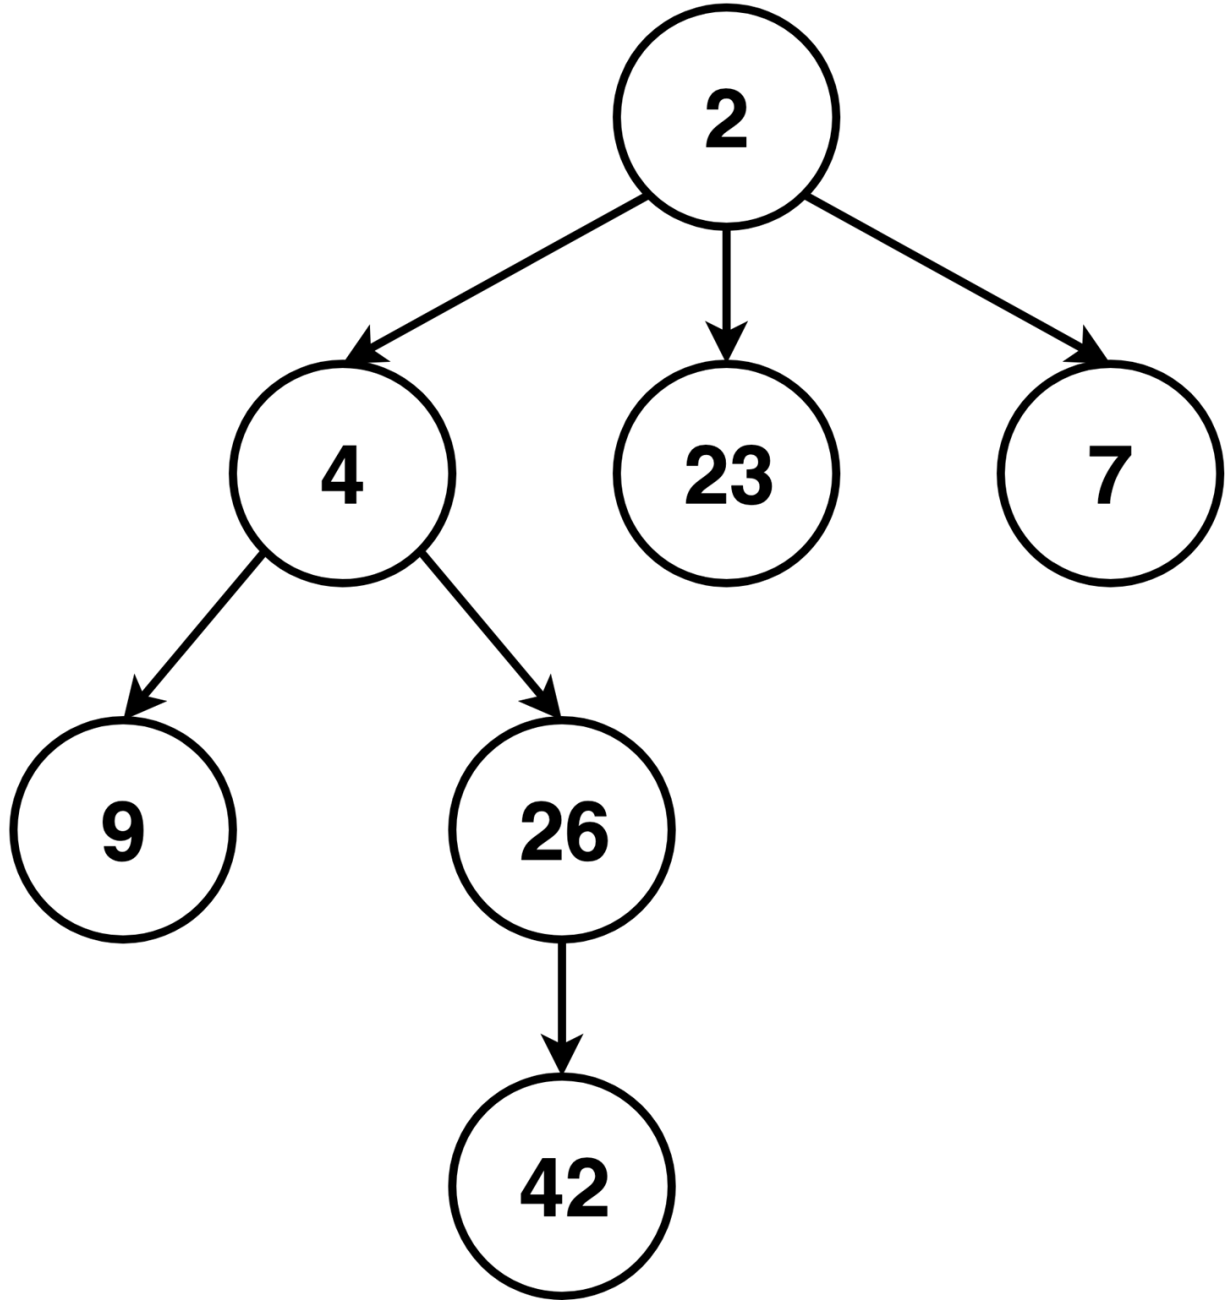
2
4
23
7
9
26
42

Úrovne stromu

- koreňový uzol je na nultej úrovni
- hĺbka – vzdialenosť od koreňového uzla (počet hrán)
- uzly v rovnakej hĺbke sú na jednej úrovni

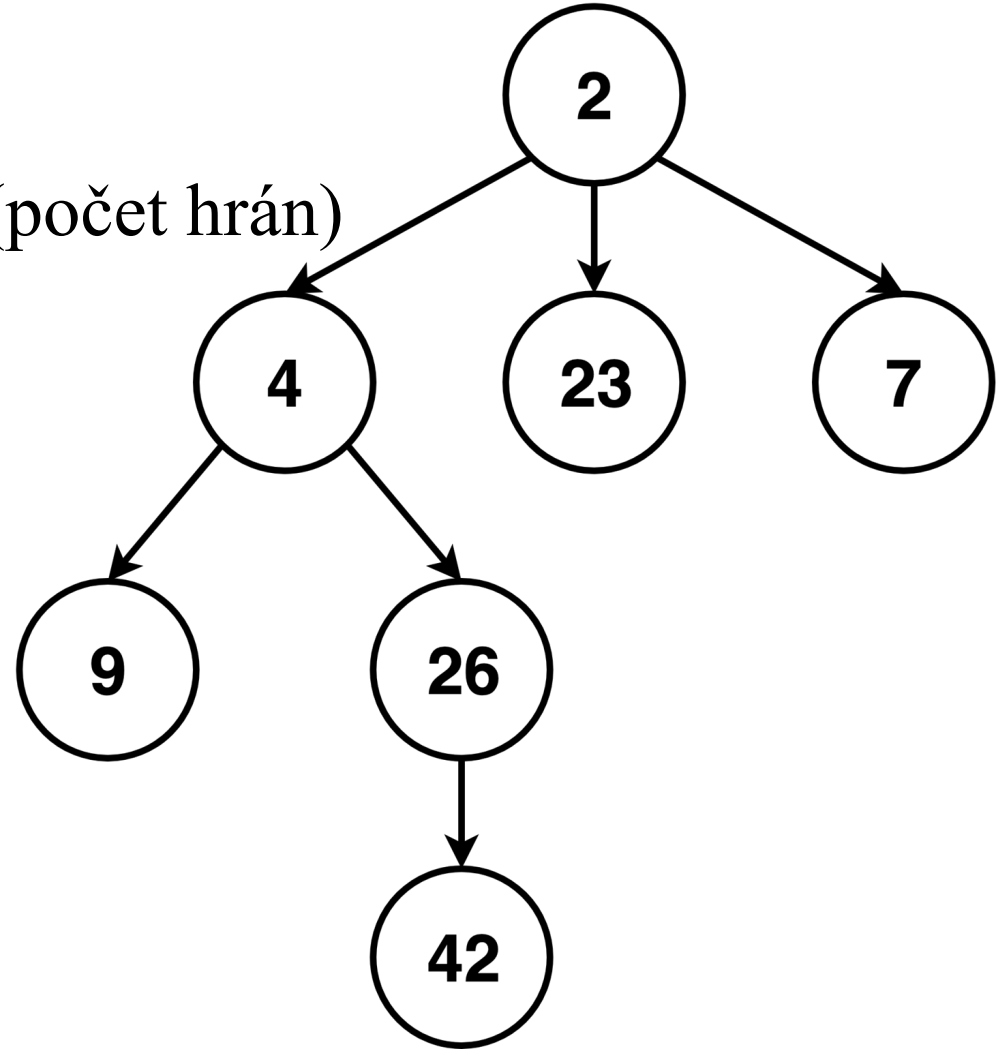

Výška stromu

- udávaná uzlom s najväčšou hĺbkou
- dĺžka maximálnej cesty od koreňového uzlu po uzol s najväčšou hĺbkou

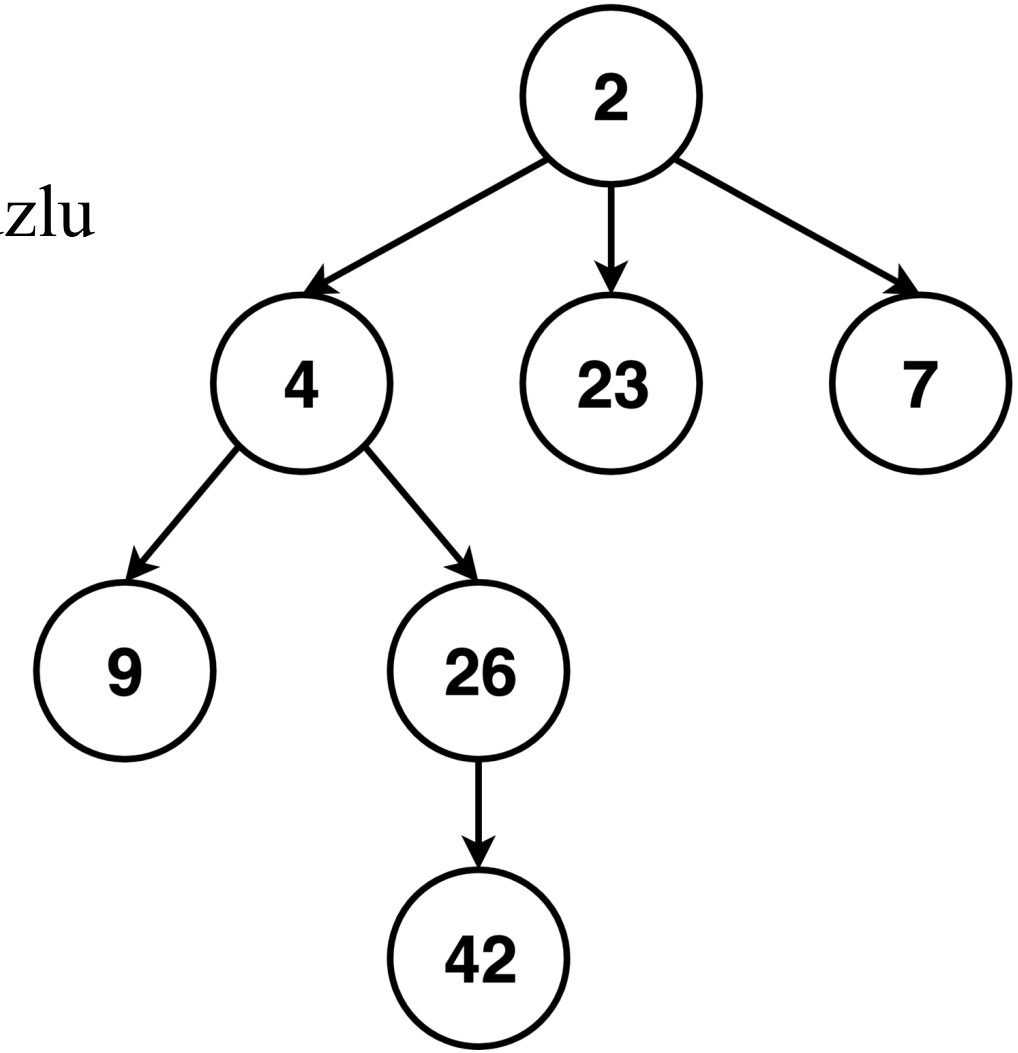

Binárny strom

- stromová štruktúra, v ktorej každý uzol má maximálne dvoch potomkov
- striktný binárny strom – každý uzol má 0 alebo 2 potomkov
- maximálny počet uzlov na úrovni *i*:
  2^i
- maximálny počet uzlov v strome s výskou *h*:
  $2^{h+1} - 1$

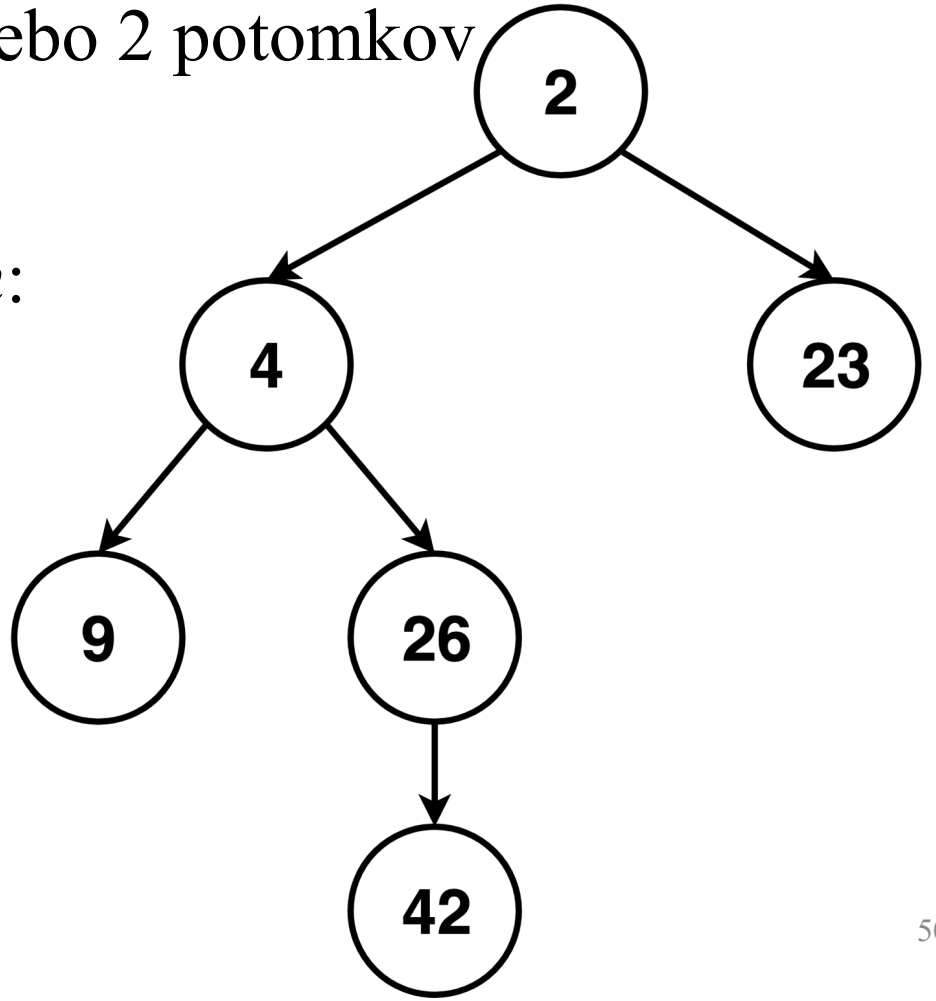

Vyvážený binárny strom

- binárny strom, v ktorom každá úroveň je plne obsadená až na poslednú, v ktorej uzly sú čo najviac vľavo
- rozdiel medzi výškou dvoch potomkov je maximálne 1
- ak aj posledná úroveň je plne obsadená, nazýva sa to aj perfektný binárny strom
- výška stromu s *n* uzlami:

$$h = \lfloor \log_2(n + 1) - 1 \rfloor$$

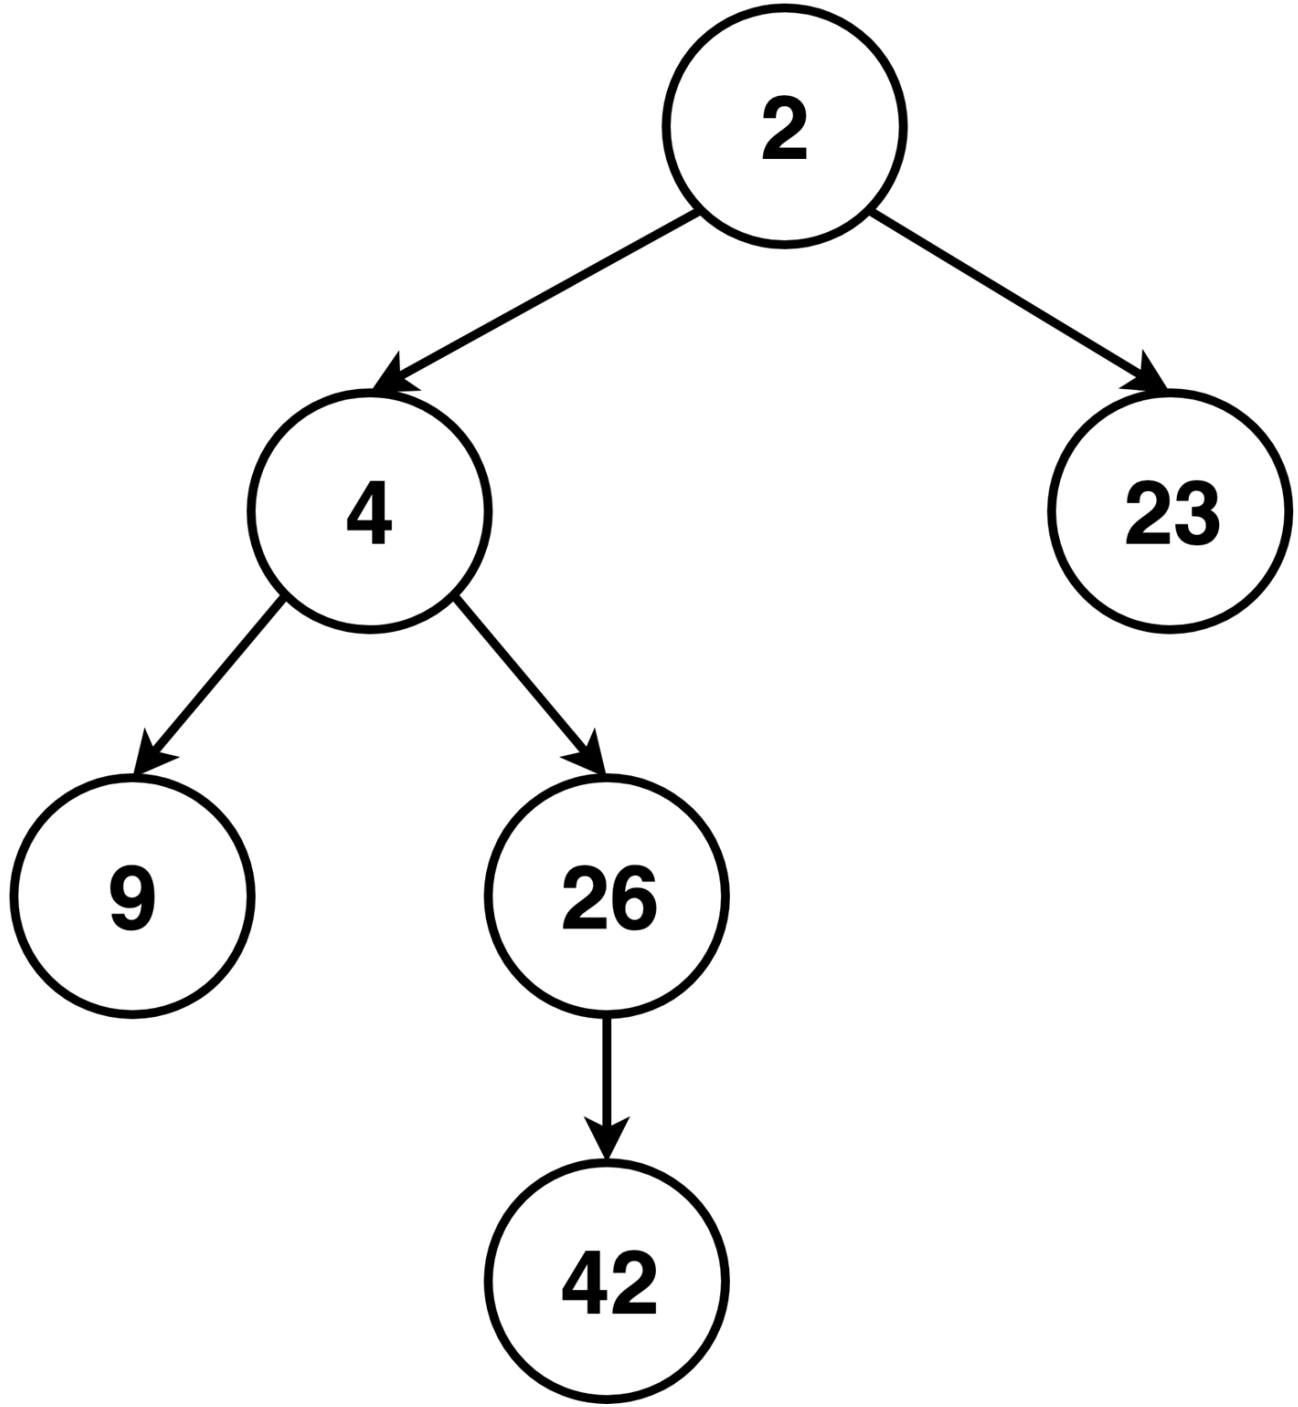
2
4
23
9
26
42

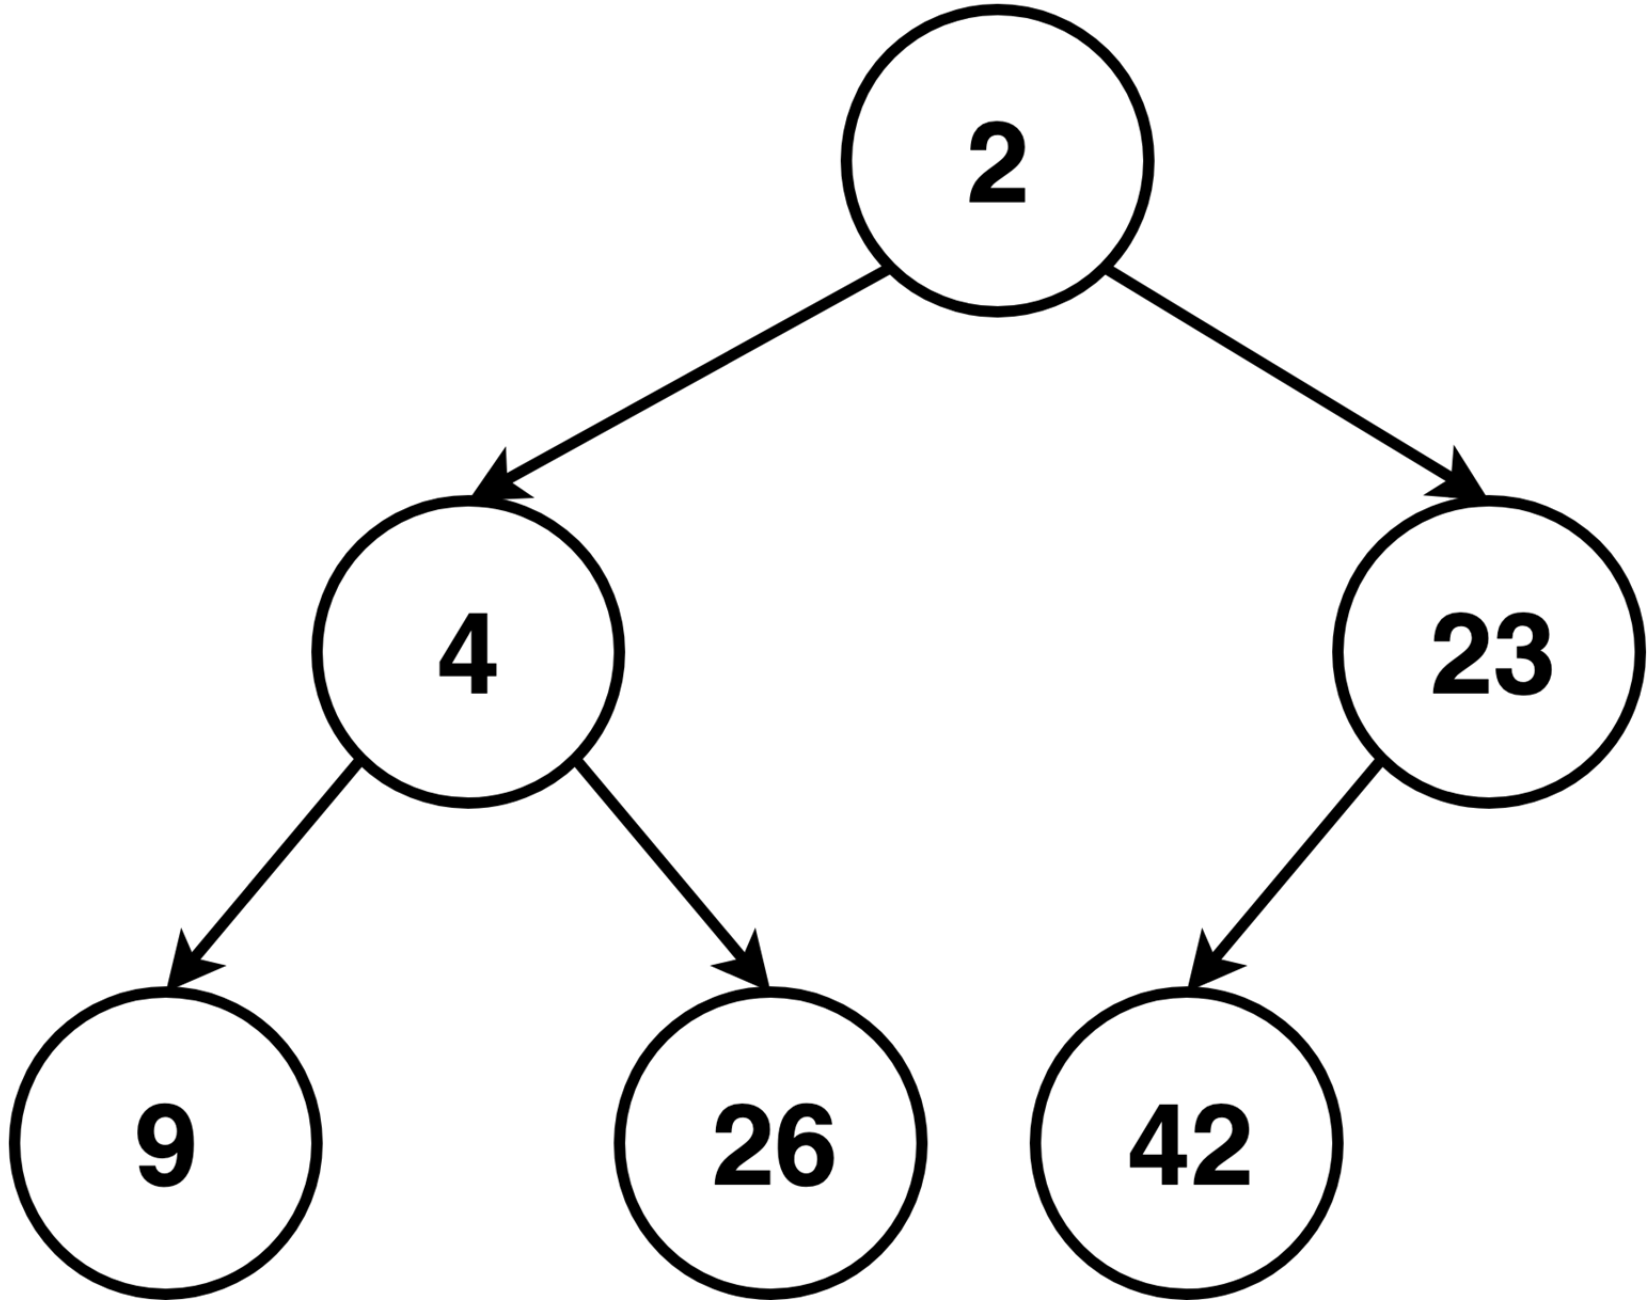
2
4
23
9
26
42

Reprezentácia stromov pomocou uzlov

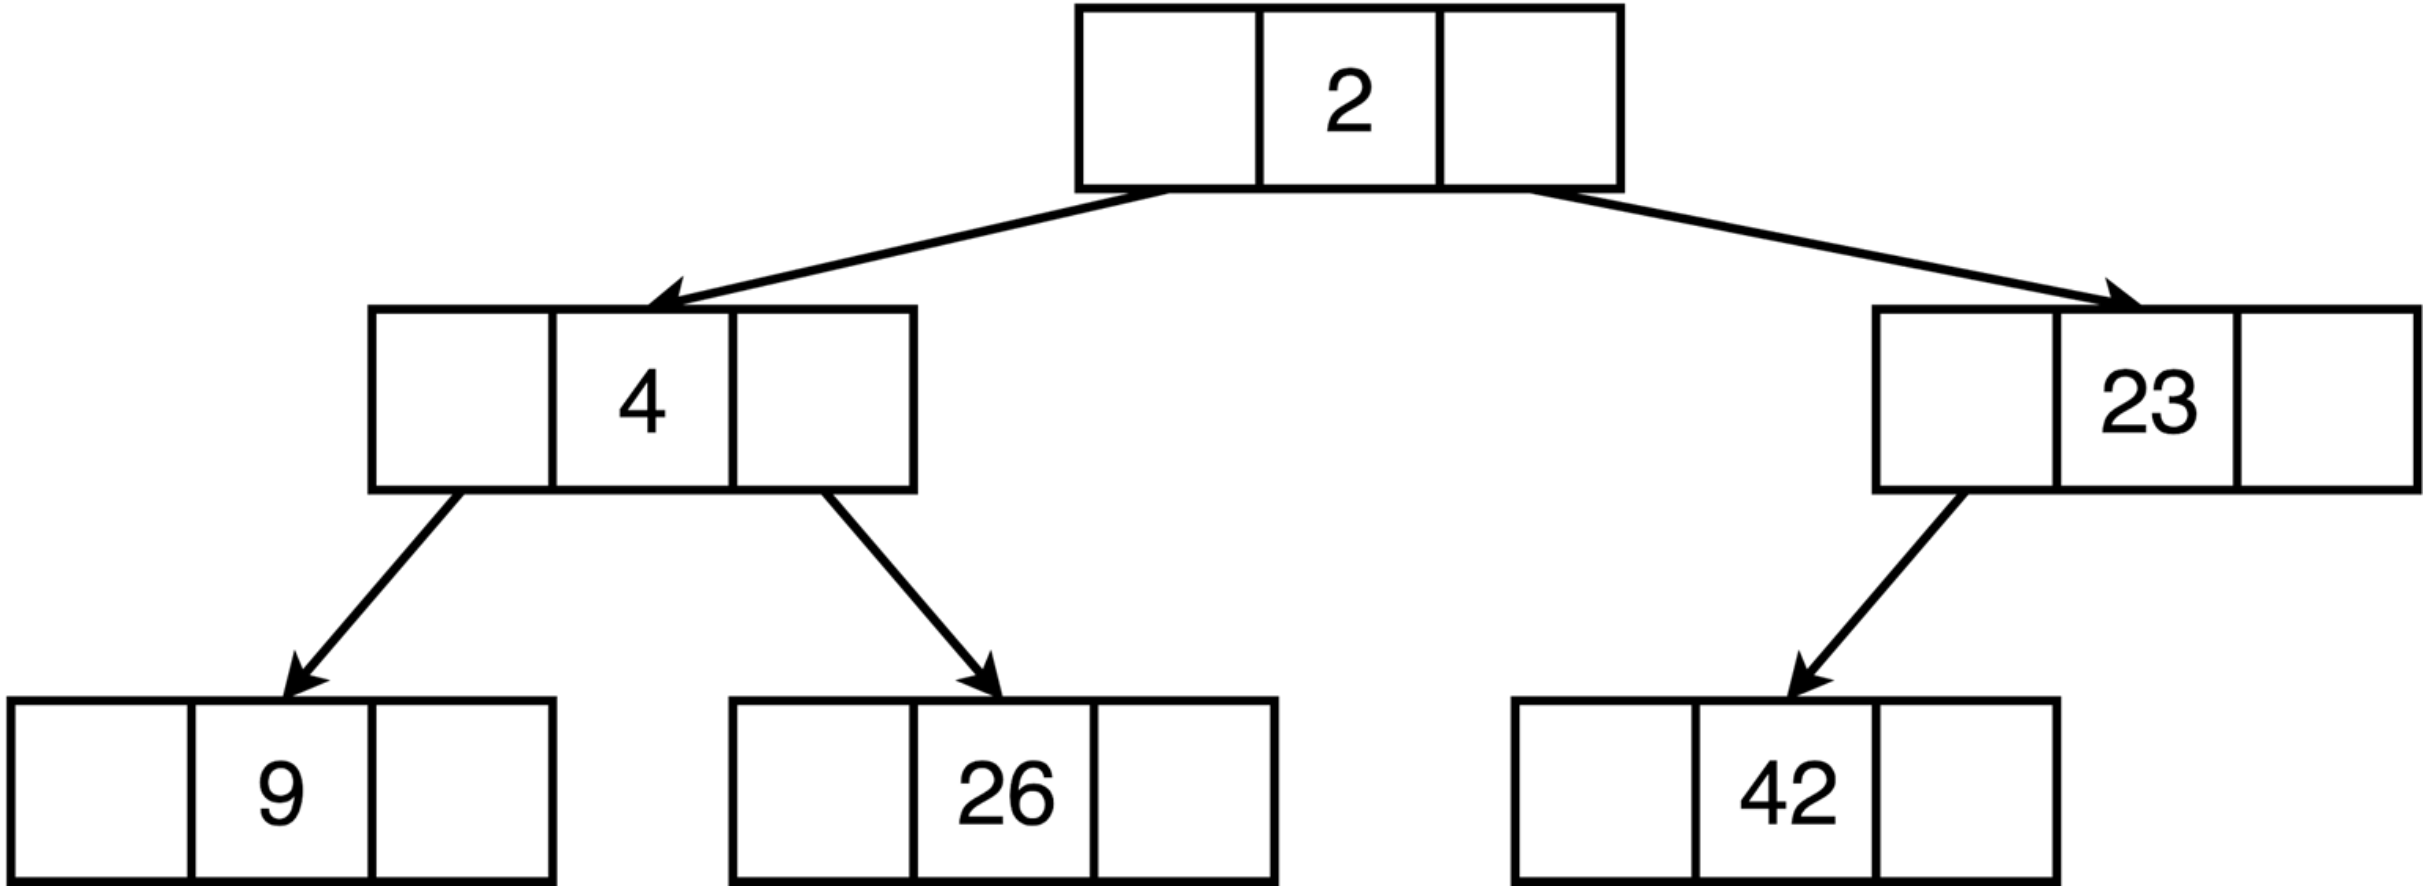

Reprezentácia stromov pomocou zoznamu

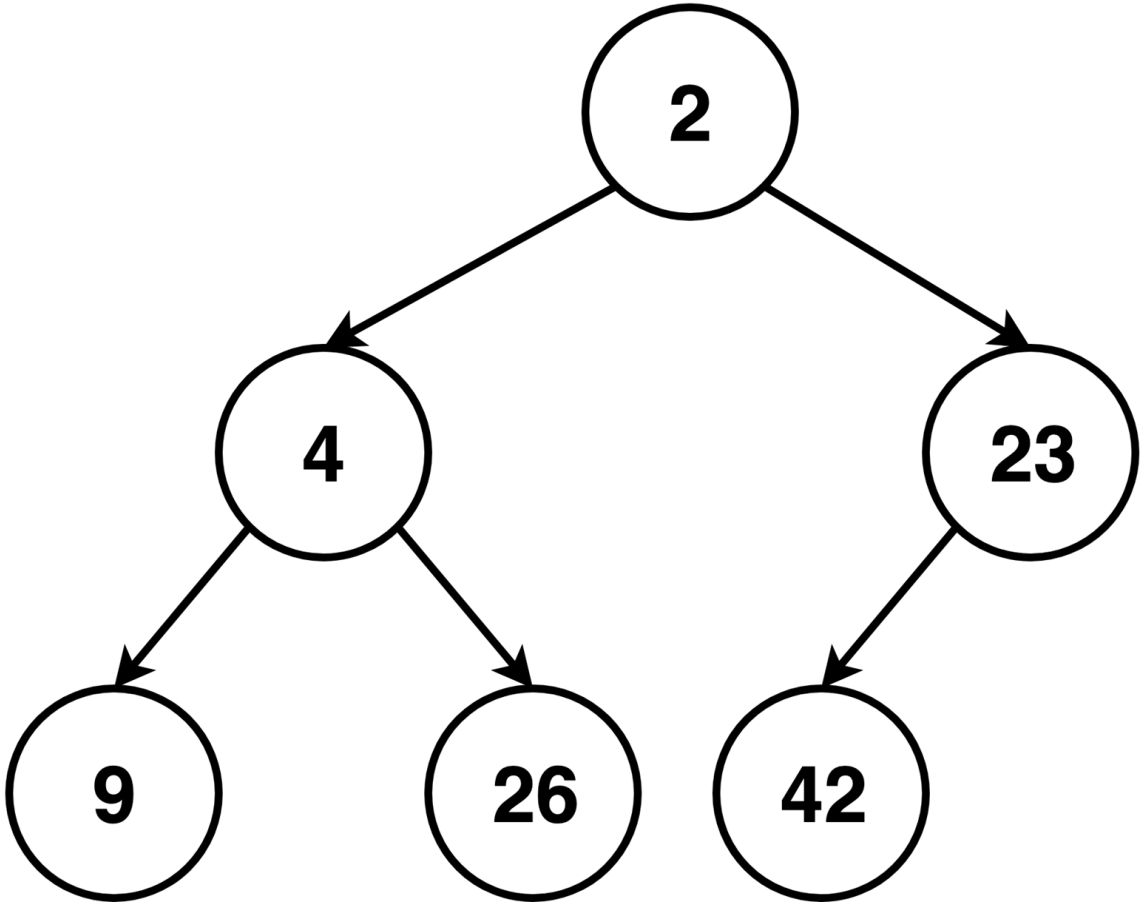

- pre uzol s indexom *i*:
  - ľavý potomok má index *2i+1*
  - pravý potomok má index *2i+2*

2	4	23	9	26	42

Binárny vyhľadávací strom

- binárny strom, v ktorom pre každý uzol platí, že hodnoty v ľavom potomkovi sú menšie ako hodnota uzla, a hodnoty v pravom potomkovi sú vyššie ako hodnota uzla

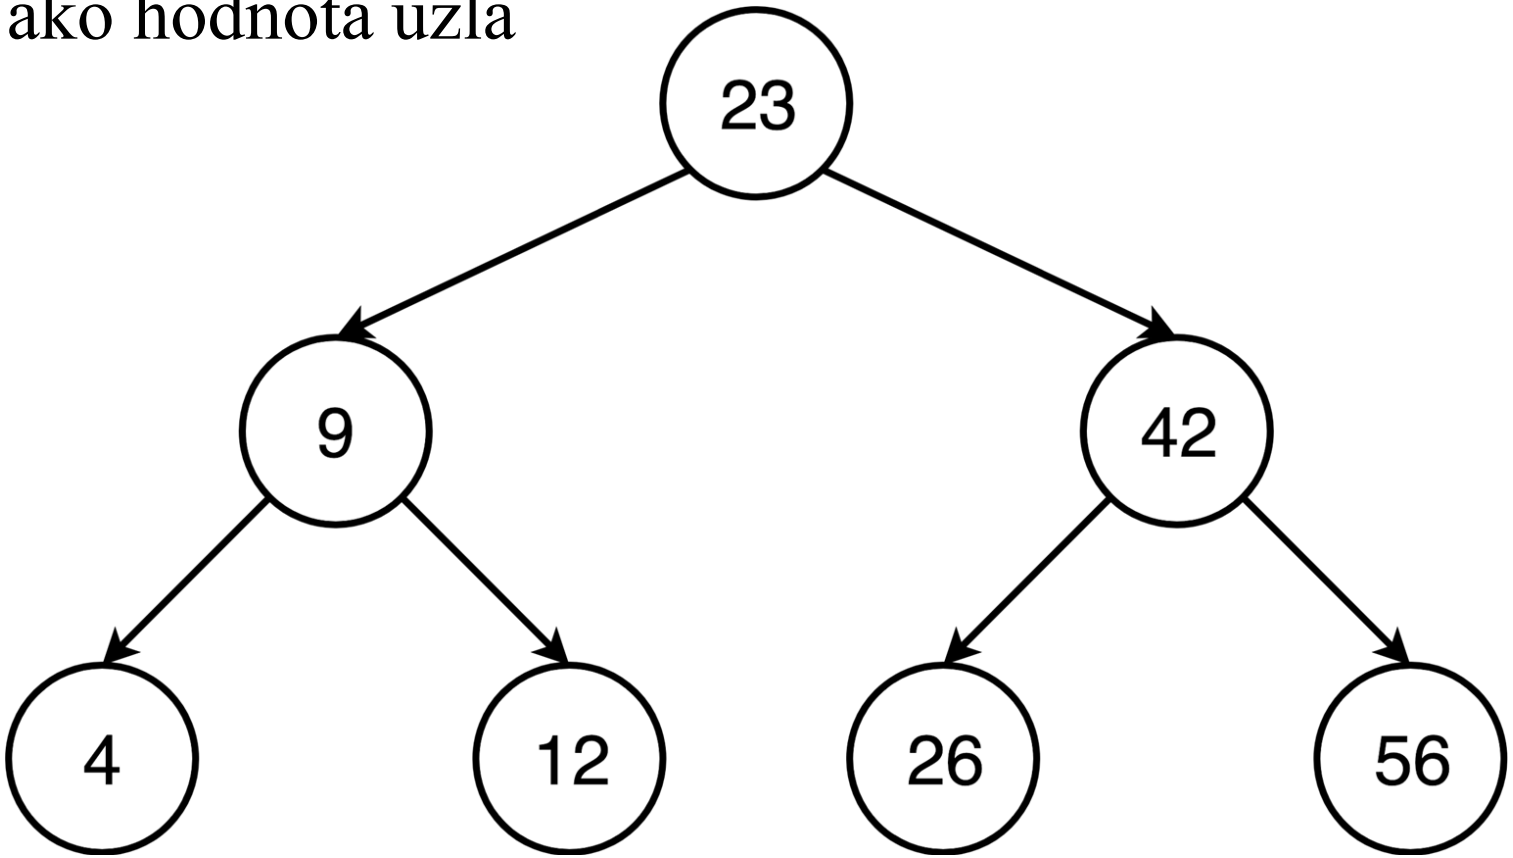

Vyhľadávanie - zoznam vs. strom

2	4	9	23	26	42	56

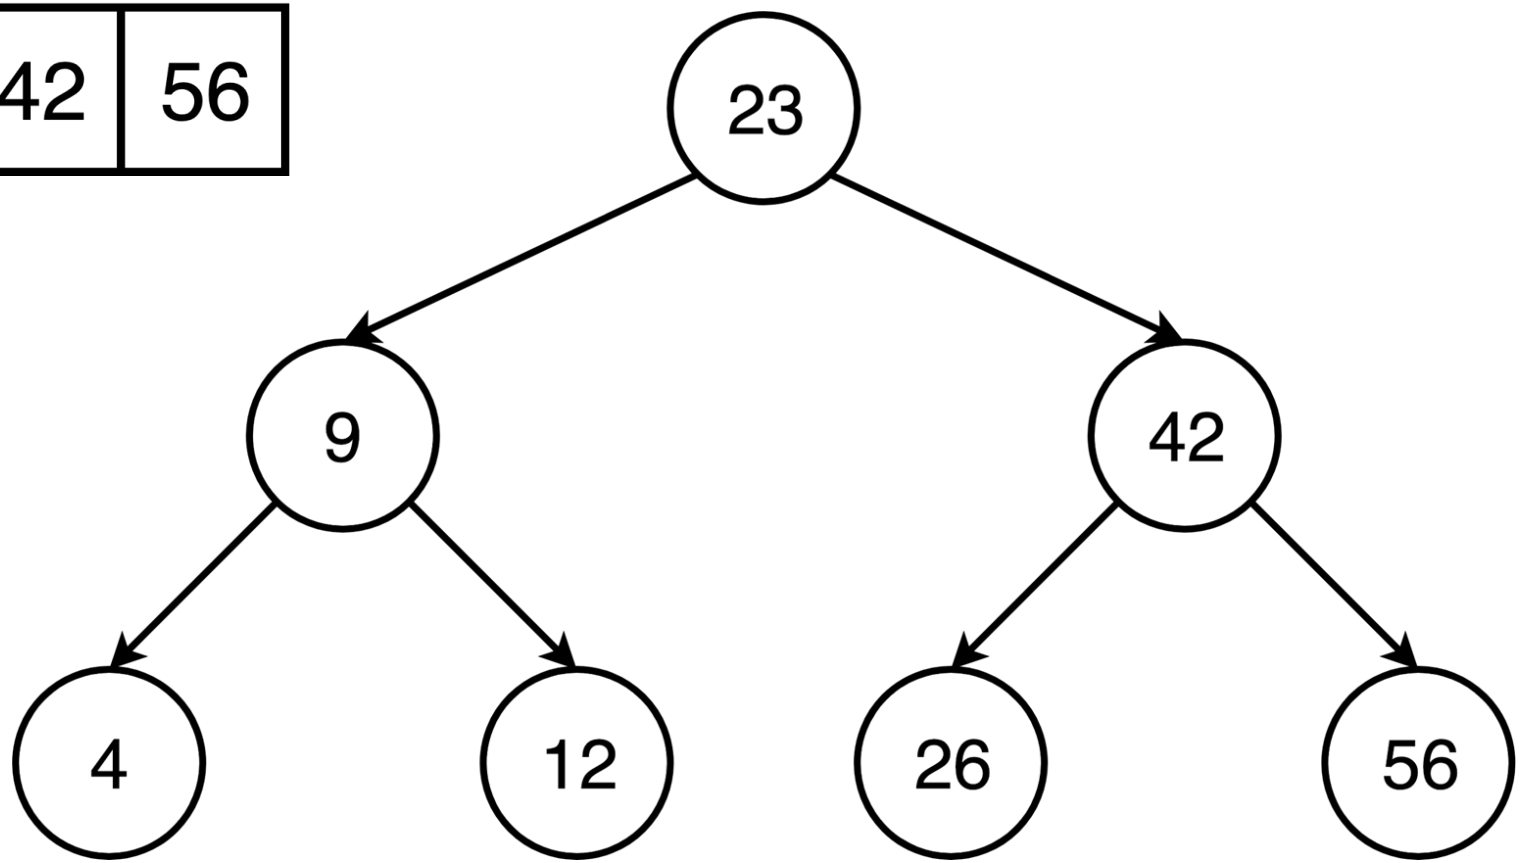

Pridávanie prvkov do stromu

1. nájsť vhodné miesto
2. pridať uzol
3. upraviť strom ak sa stane nevyváženým

pridaj 28

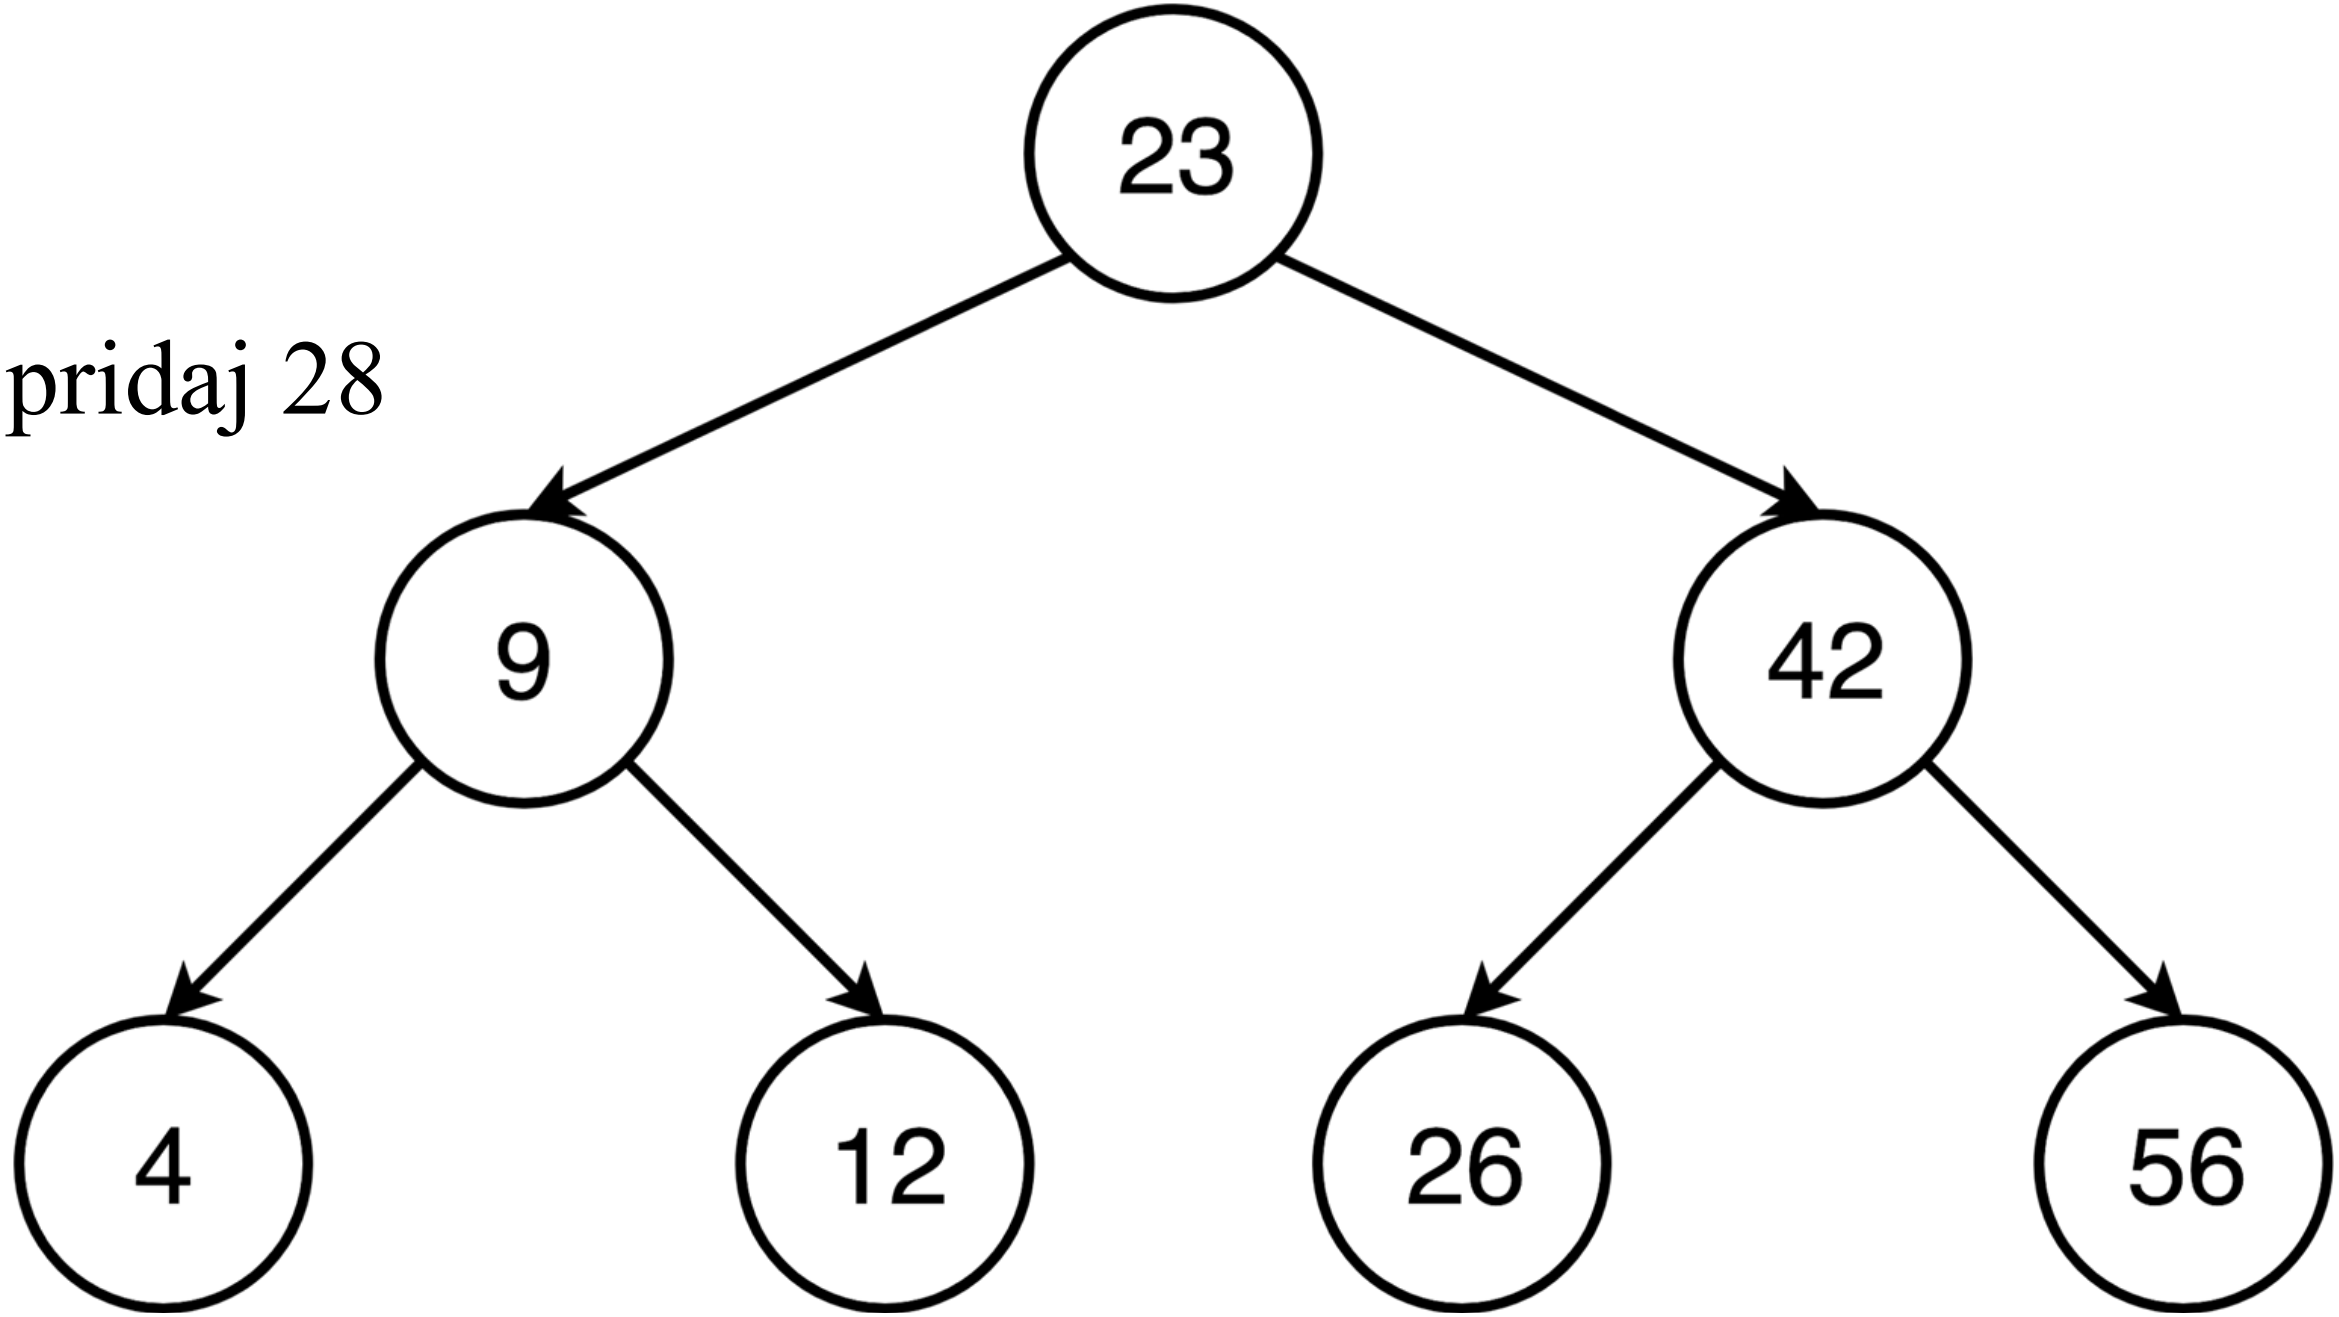

pridaj 27

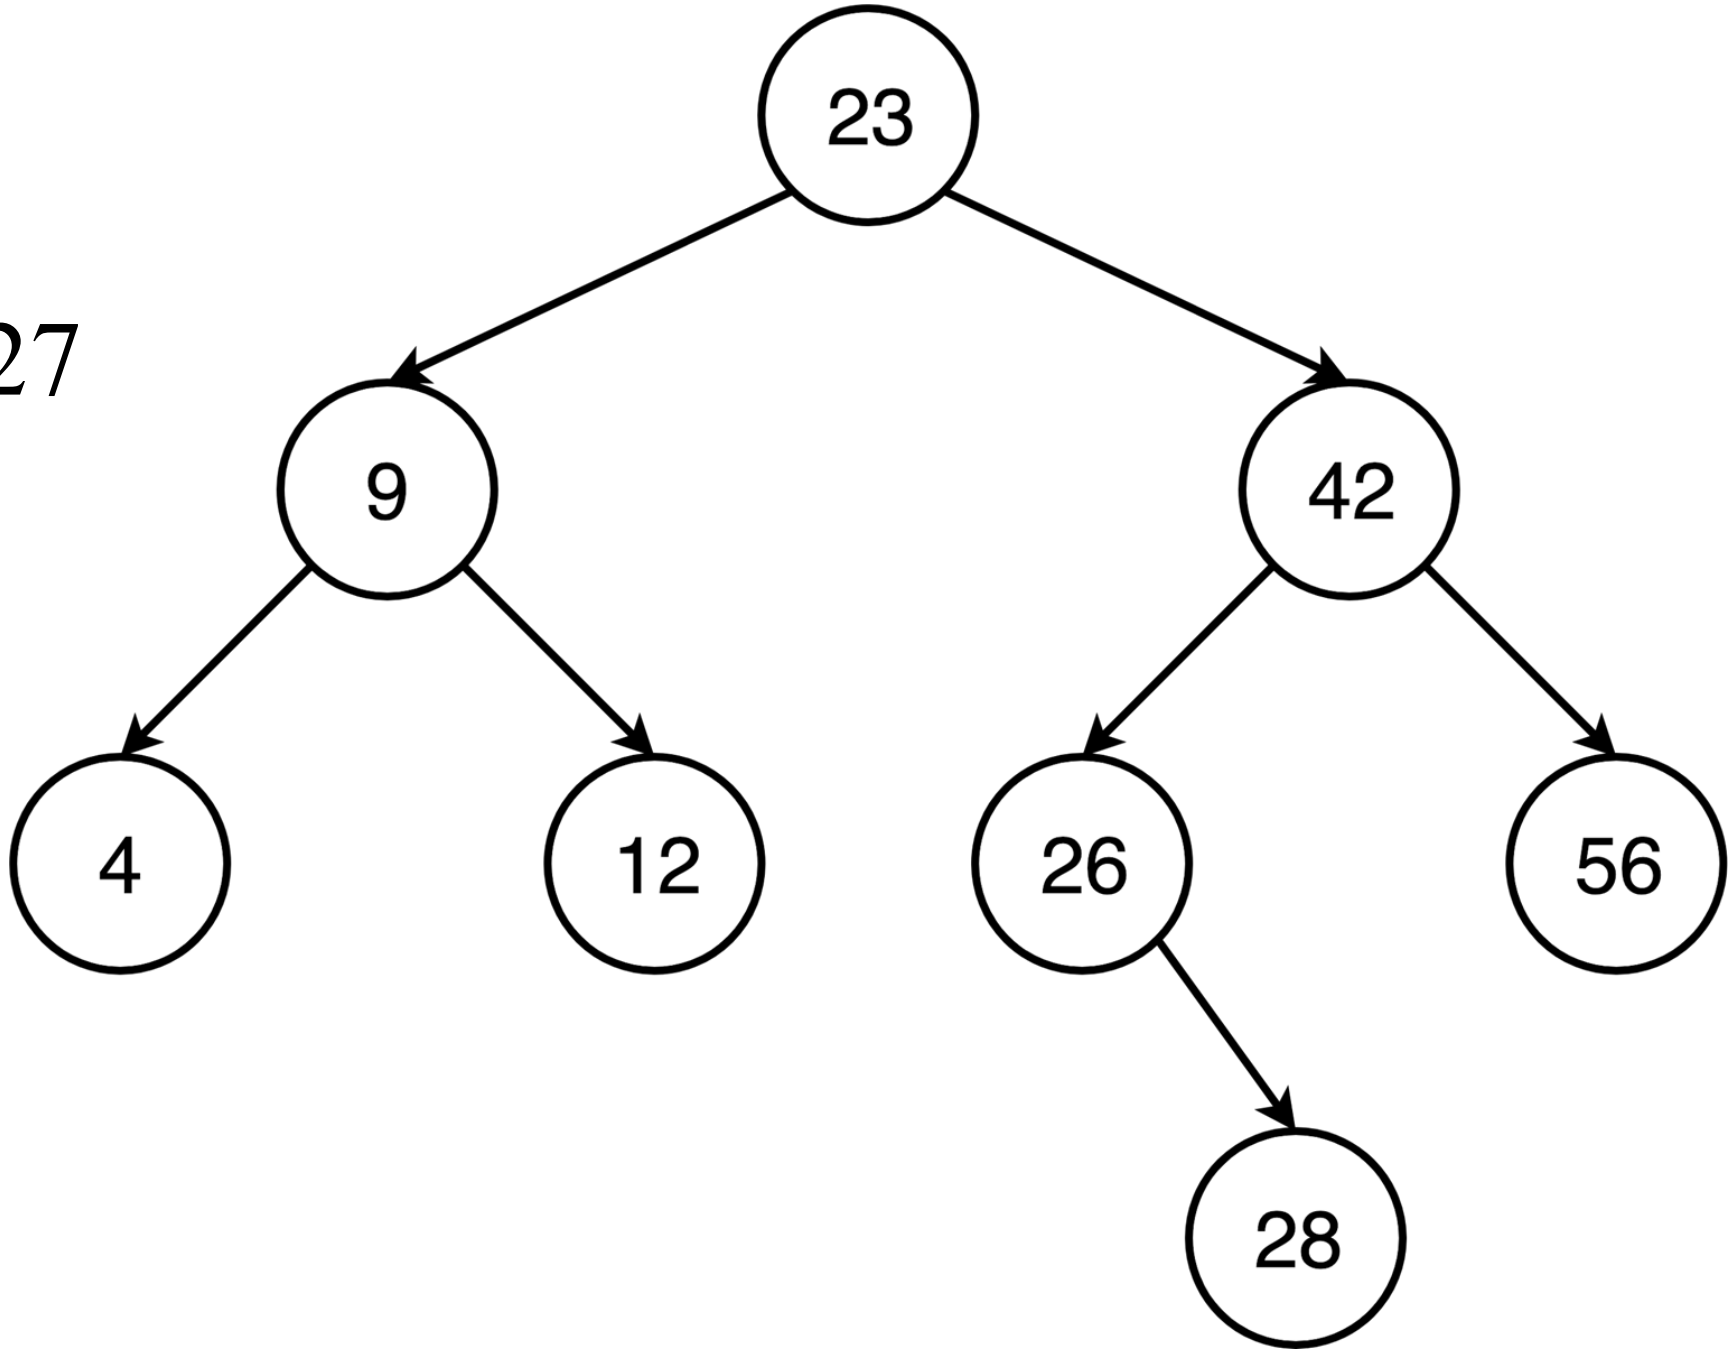

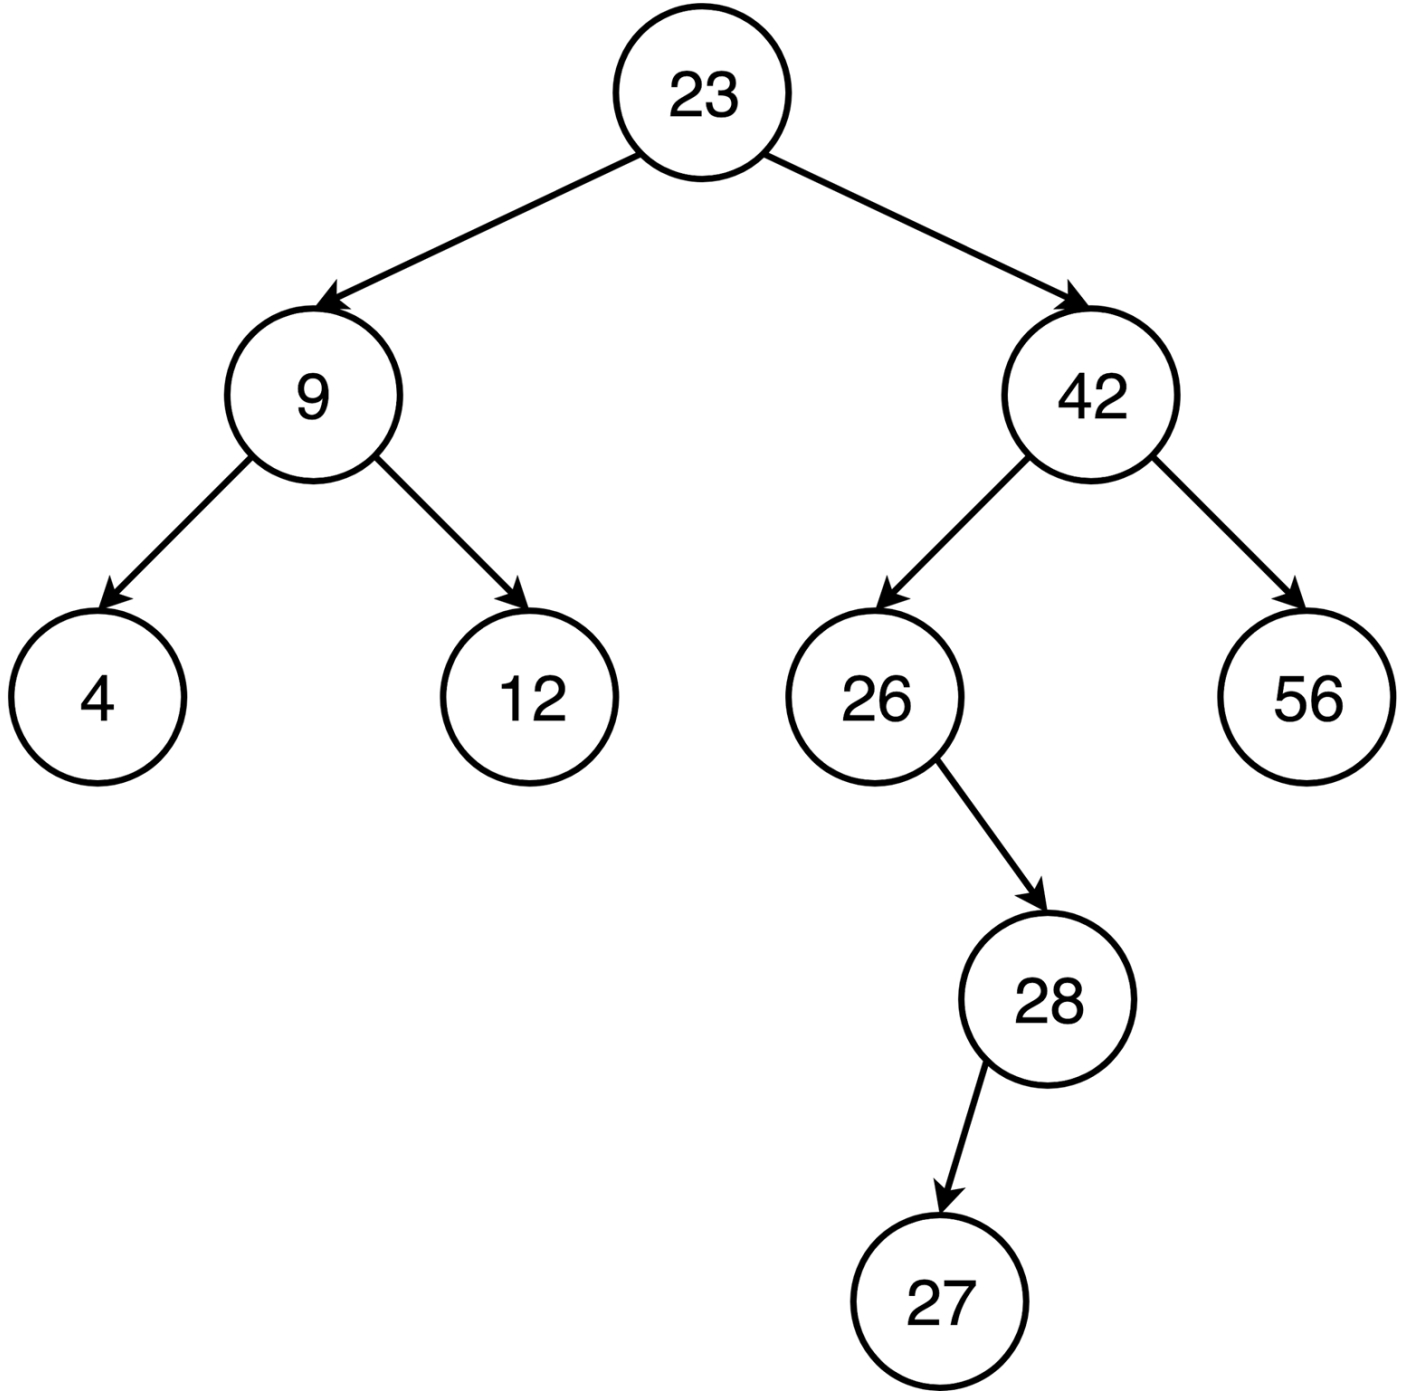
23
9
42
4
12
26
56
28
27

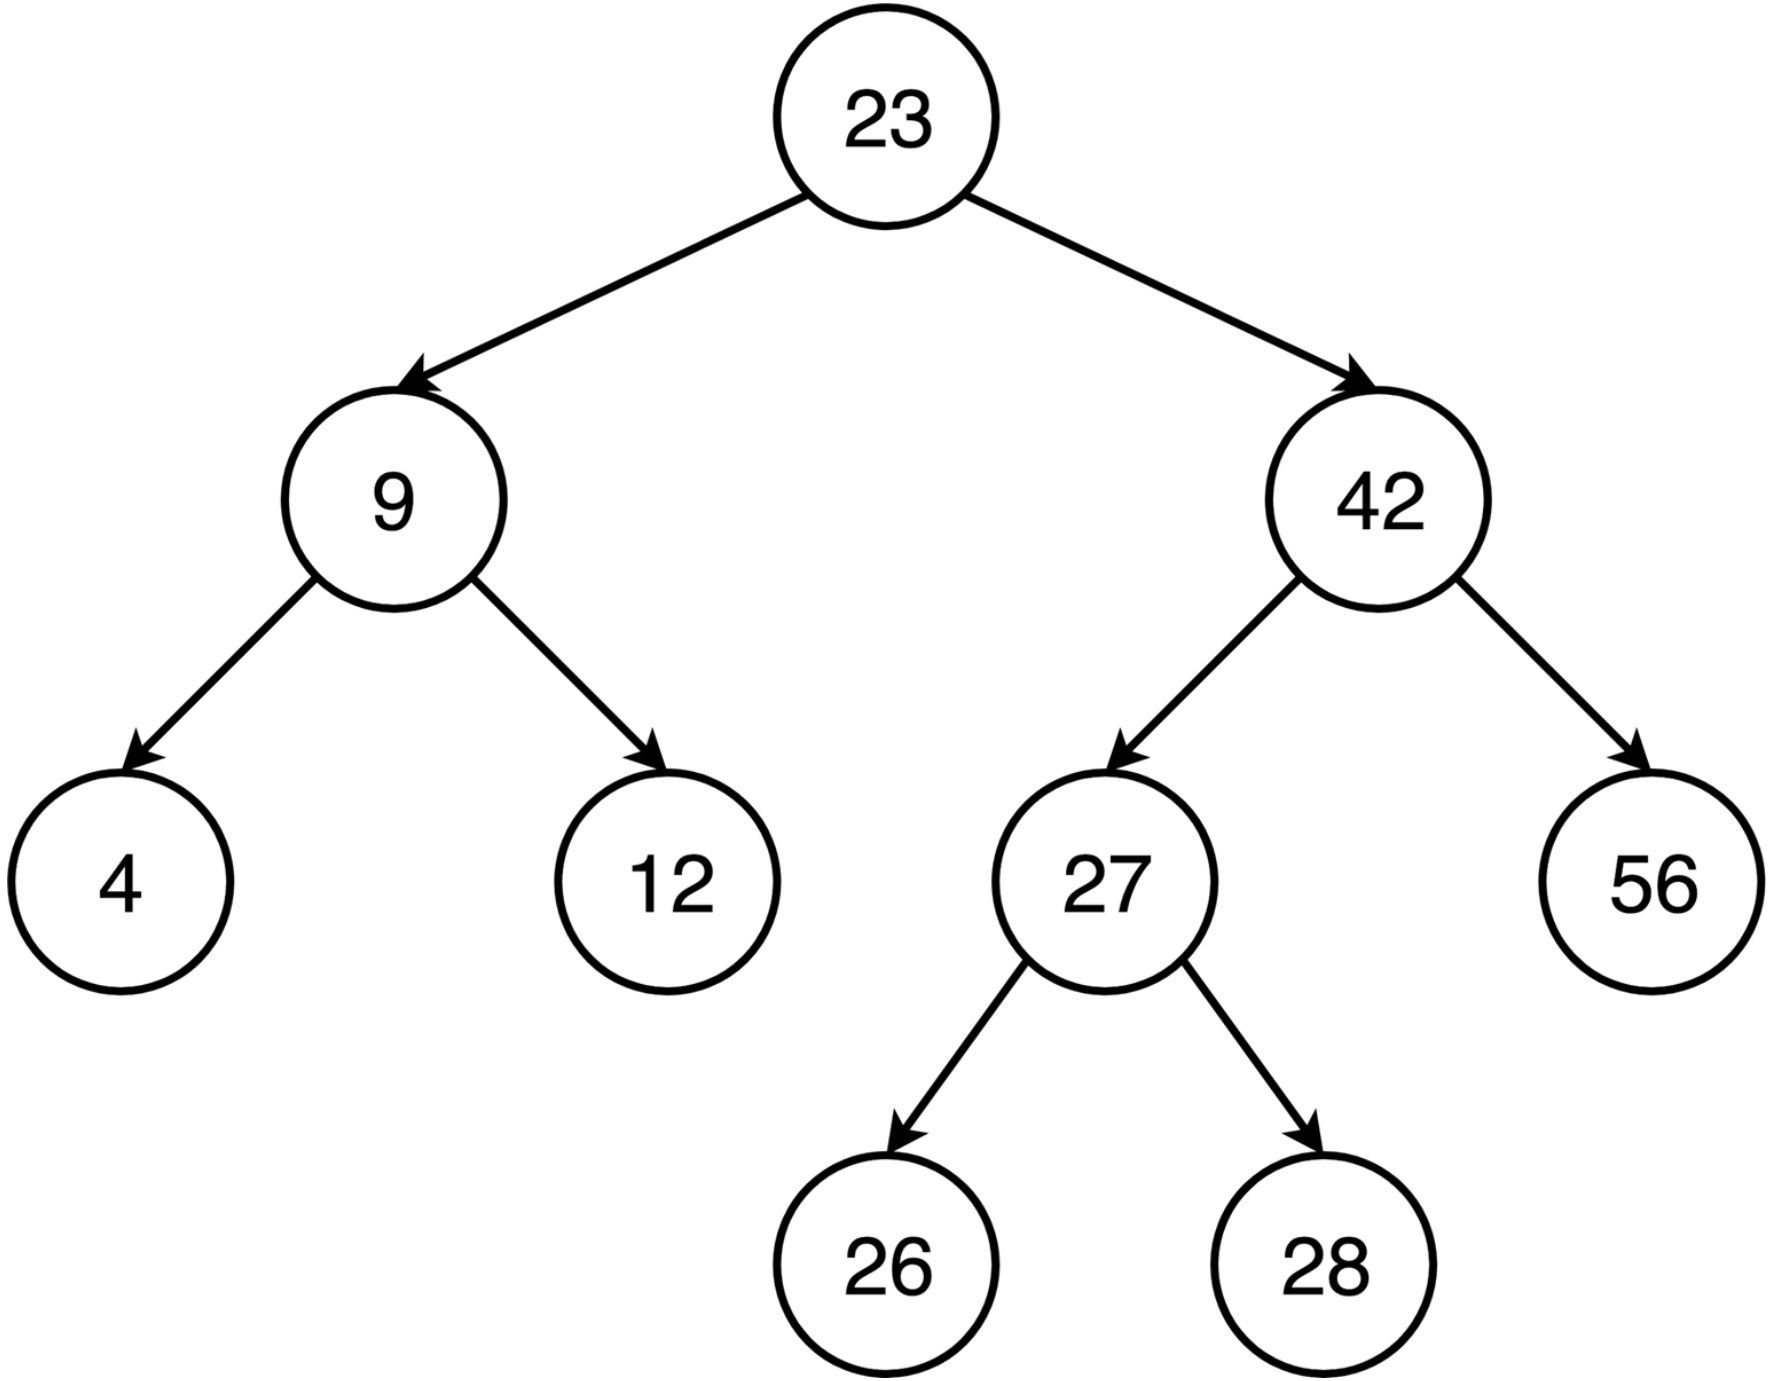
23
9
42
4
12
27
56
26
28

Porovnanie náročnosti operácií – zoradené hodnoty

Operácia	**Pole**	**Spojkový zoznam**	**BVS**
Vyhľadávanie	*O(log n)*	*O(n)*	*O(log n)*
Pridávanie	*O(n)*	*O(1)**	*O(log n)**
Zmazanie	*O(n)*	*O(n)*	*O(log n)*

Zhrnutie

- údajové štruktúry
- polia
- numpy a pandas
- spojkové zoznamy
- zásobník a front
- hašovacia tabuľka
- stromy